ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет информатики, математики и компьютерных наук

Программа подготовки бакалавров по направлению
01.03.02 Прикладная математика и информатика

Спасюк Мария Ильинична, Филатов Артем Андреевич

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА БАКАЛАВРА

Распознавание синтетических видео на основе анализа микро-выражений лиц для онлайн конференций

Рецензент:
Приглашенный преподаватель
кафедры прикладной математики
и информатики
А.А. Шимко

Научный руководитель:
д-р технических наук,
профессор кафедры
информационных
систем и технологий
А.В. Савченко

Нижний Новгород
2026

Содержание

Введение **3**

1 Глава 1. Обзор существующих методов **6**

1.1 Датасеты 6

1.2 Инструменты генерации видео 7

1.3 Инструменты распознавания фейковых видео 10

2 Глава 2. Реализованный подход **13**

2.1 Сбор данных 13

2.1.1 Сбор реальных видео 13

2.1.2 Сбор синтетических видео 14

2.1.3 Мультимодальная аннотация и аугментации 15

2.1.4 Предобработка данных 19

2.2 Алгоритм распознавания синтетических видео 20

3 Глава 3. Результаты экспериментов **24**

3.1 Итоговая модель 25

3.2 Другие подходы и эксперименты 26

3.2.1 RGB-модальность 26

3.2.2 Признаки, извлеченные с глаз 32

3.2.3 Facial landmarks 34

3.2.4 rPPG 37

3.3 Использованные вычислительные ресурсы 39

Список использованной литературы **42**

Введение

Модели искусственного интеллекта развиваются очень стремительно и применяются во многих сферах жизни общества. Однако в то же время они становятся инструментом обмана людей. Так как методы генерации синтетических видео на текущий момент позволяют создавать видео людей, сложно отличимые от реальных, учащаются случаи использования моделей искусственного интеллекта с неблагоприятными намерениями и в целях мошенничества.

Распознавание синтетических видео играет огромную роль для борьбы с мошенническими схемами, в которых применяется сгенерированный контент. Известны случаи, когда с помощью дипфейков мошенникам удавалось получать деньги или конфиденциальную информацию о нужных им людях. Например, в 2024 году сотрудник финансового отдела компании в Гонконге перевел мошенникам 25,6 миллионов долларов США после видеоконференции с финансовым директором и другими сотрудниками компании. Все участники конференции, кроме сотрудника, совершившего денежные переводы, оказались сгенерированными ИИ [1]. Помимо этого, существуют и другие распространенные схемы мошенничества с использованием генеративных способностей моделей ИИ. Например, проведение онлайн-собеседования с рекрутером компании, который является дипфейком, а не реальным человеком, с целью получения данных банковских карт кандидата.

По мере развития технологий генерации изображений и видео, появляются и новые методы распознавания синтетических видео. Однако, одной из основных проблем классических подходов к распознаванию дипфейков лица является их обучение на устаревших датасетах — CelebDF [2],

FaceForensics++ [3], DFDC [4] и др. Эти известные крупные датасеты с синтетическими видео созданы с помощью методов, которые по качеству генерации уступают новейшим моделям искусственного интеллекта. Например, современные методы создания фейковых видео лица человека генерируют более натуральные микровыражения и эмоциональные реакции, в отличие от более старых моделей (Face2Face [5], Deepfakes [6] и др.). Соответственно детекторы, обученные на старых наборах данных, неэффективны в распознавании фейковых видео, сгенерированных SOTA-методами (sota – state-of-the-art). Эксперименты в практической части работы это подтверждают.

В данной работе рассматриваются следующие способы генерации видео:

- Генерация видео при помощи замены лица на реальном видео (Deep Live Cam [7]);
- Генерация видео с использованием аудио-дорожки и изображения лица человека (MoDA [8], StableAvatar [9]);

Также в работе рассматриваются классические архитектуры (CNN, RNN, LSTM, attention-based подходы), а также различные методы детекции (LRNet [10], DeepFakesOn-Phys [11]), в которых особое внимание уделяется анализу микровыражений и эмоций человека.

Цель работы: Собрать подходящий набор данных из различных источников (реальных видео лиц с телеконференций) и синтетические видео, сгенерированные с помощью SOTA-методов, в том числе учитывающие вариативность расы, пола, возраста и эмоционального состояния. Разработать легковесные real-time алгоритмы распознавания синтетических видео на основе анализа микровыражений лиц.

Задачи:

1. Исследовать и протестировать различные SOTA-методы для генерации видео с лицами;
2. Собрать датасет, состоящий из 7000 синтетических видео и 3000 реальных видео лиц, отслеживая разнообразие рас, гендеров, возраста и эмоций;
3. Исследовать и протестировать различные архитектуры и методы для задачи распознавания фейковых видео, работающие с микровыражениями и подходящие для работы в реальном времени;
4. Выбрать предобученные легковесные модели детекции и дообучить их на собранном датасете;
5. Протестировать итоговое решение на новых данных и провести анализ полученных результатов.

1 Глава 1. Обзор существующих методов

1.1 Датасеты

Для разработки и оценки алгоритмов распознавания фейковых видео важным является использование репрезентативных наборов данных. Наибольшее распространение получили датасеты FaceForensics++ [3], Celeb-DF(v2) [2] и Deepfake Detection Challenge (DFDC) [4], так как они отражают разные уровни сложности синтетических видео и позволяют оценивать устойчивость моделей в различных условиях.

FaceForensics++ является часто использующимся бенчмарком, содержащим 1000 исходных видеороликов с YouTube с лицами людей. Для каждого исходного видео были сгенерированы фейки с помощью методов DeepFakes [6], Face2Face [5], FaceSwap [12] и NeuralTextures [13]. Также датасет содержит 3 варианта разрешения видео, что позволяет обучать модели на различных условиях. Celeb-DF(v2) [2] был создан как более сложный набор данных, чем FF++ [3]. Он включает 590 реальных видео знаменитостей и 5639 поддельных, сгенерированных улучшенным алгоритмом DeepFakes, что обеспечило более высокое визуальное качество синтетических видео. DFDC [4] представляет собой один из крупнейших датасетов, насчитывающий более 119 000 видеоклипов. Фейковые видео были сгенерированы широким спектром методов, включая GAN-подходы [14].

Несмотря на значительный вклад перечисленных наборов данных в развитие алгоритмов распознавания дипфейков, на текущий момент их репрезентативность для обучения современных детекторов существенно снизилась. Это обусловлено стремительным развитием генеративных алгоритмов. Рассмотренные датасеты опираются на методы генерации, которые

сейчас значительно уступают SOTA-методам.

Современные инструменты создания фейковых видео, использующие диффузионные модели, продвинутые архитектуры трансформеров и современные модификации GAN с высоким разрешением, генерируют видео значительно лучшего качества. Они практически не оставляют пространственно-временных артефактов, таких как мерцание, размытые границы наложения лица или геометрические искажения, на поиске которых специализируются детекторы, обученные на FaceForensics++ [3], Celeb-DF [2] и DFDC [4]. Таким образом, классификаторы, обученные только на этих данных, переобучаются на специфические паттерны старых алгоритмов генерации и демонстрируют низкую обобщающую способность при анализе высококачественных фейков.

1.2 Инструменты генерации видео

Задача генерации видео является более сложной, чем генерация статических изображений, из-за необходимости моделировать согласованную во времени динамику сцен и объектов. Первые подходы к данной задаче основывались на генеративно-состязательных сетях (GAN) и вариационных автоэнкодерах (VAE), однако они часто характеризуются нестабильностью обучения и ограниченной способностью моделировать долгосрочные временные зависимости. Наиболее часто используемый подход в SOTA-методах — диффузионные модели, часто диффузионные трансформеры, которые постепенно удаляют шум из гауссовского начального распределения, используя текстовую, аудио или визуальную информацию. Диффузионные модели превзошли GAN по качеству и разнообразию генерируемых видео. Современные диффузионные и гибридные подходы обеспечивают

плавность движений, точную синхронизацию губ и высокую согласованность изображения во времени, но также имеют недостаки в виде высокой вычислительной сложности и времени вывода.

Касательно входных данных для генерации видео, выделяют четыре основных метода: замена лица (face swap), "говорящая голова"(talking head), генерация полностью синтетического материала, используя текстовое описание (text to video), а также перенос мимики и некоторых черт лица с одного на другое (face reenactment). Для подхода с talking head часто используется аудио и эталонное изображение. Этот подход используют такие методы, как Wav2Lip [15], Hallo2 [16], OmniAvatar [17], HunyuanVideo-Avatar [18] и другие. Синтезируя видео высокого качества, они, однако, могут демонстрировать ненатуральные выражения лица и движения головы, расхождения в движениях губ с аудио, а также ограничены созданием коротких видеороликов с аватарами продолжительностью менее 15 секунд. При попытке создания видеороликов продолжительностью более 15 секунд возникают значительные искажения фигуры и несоответствия внешнего вида, особенно в области лица.

С аудио и референсным изображением также работают методы генерации StableAvatar [9] и MoDA [8]. Диффузионный трансформер StableAvatar [9] обеспечивает стабильную идентичность персонажа и синхронизацию артикуляции на протяжении тысяч кадров без постобработки и решает проблему накопления ошибок латентного распределения при внедрении аудиопризнаков в диффузионную модель. Метод MoDA [8] также подходит для генерации длинных видео и решает проблему межмодальных несоответствий, моделируя взаимодействие между модальностями (движение, аудио, эмоции, идентичность) с помощью мультимодального диффузионного трансформера и стратегии слияния признаков.

Замена лица (face swap) на видео или изображении также является широко используемым видом манипуляций. Этот подход начал использоваться одним из первых для создания фейковых видео с лицами людей. В известном наборе данных Face Forensics++ часть видео была сгенерирована с помощью методов FaceSwap [12] и DeepFakes [6], качество работы которых значительно уступает более современным подходам, например, методу Deep Live Cam [7]. Он основан на модели замены лица inswapper128, а также использует модель улучшения лица GFPGAN 1.4 [19] для повышения качества финального изображения. Улучшайзер лиц - это GAN, которая удаляет артефакты сжатия, повышает резкость и восстанавливает мелкие детали, текстуру кожи, таким образом делая результат после замены лица более естественным.

Такие решения, как MoDA [8] и StableAvatar [9], делают упор на точную синхронизацию губ и мимики с аудио, тем самым решая проблемы межмодальной несогласованности и осуществляя временную стабильность генерации. Основными преимуществами SOTA-методов генерации видео с лицами является высокое качество синтезируемых кадров, поддержка сложных условий (длинные видео, многомодальные данные на входе) и лучшая контролируемость. Основными недостками данных методов остаются огромная вычислительная сложность, большой объем ресурсов для обучения и инференса. В отличие от методов реконструкции лица, Deep Live Cam [7] использует лёгкую модель для непосредственной замены одной идентичности на другую, после чего результат улучшается с помощью GAN. Это обеспечивает высокую частоту кадров и позволяет работать с произвольным источником лица по одному изображению. Однако Deep Live Cam [7] не обеспечивает временной согласованности на длинных видео.

1.3 Инструменты распознавания фейковых видео

Наиболее эффективными подходами в задаче детекции фейков являются те, которые учитывают не только пространственные искажения в отдельных кадрах, но и временные аномалии в последовательности видео. В глубоком обучении для работы с видео и изображениями, в частности для распознавания фейков, часто используются сверточные нейронные сети (CNN), рекуррентные нейронные сети (RNN и LSTM) и их различные комбинации [20], а также модели на базе трансформерной архитектуры.

Чистые CNN демонстрируют высокую эффективность при анализе статических изображений. Их работа основана на выявлении пространственных артефактов, таких как пиксельные несоответствия, неравномерность освещения или неестественная текстура кожи, получившаяся генеративными моделями [21]. Однако, применение только CNN к видео имеет определенные ограничения, так как модель анализирует кадры изолированно и неспособна уловить временные несоответствия, например, неестественное моргание или сбои в мимике при смене эмоций. CNN полезна для базового анализа изображений, но недостаточна для сложных сценариев, с которыми новые генеративные модели справляются все лучше.

Для анализа последовательности кадров часто используются рекуррентные сети (в частности LSTM). Эти архитектуры специально разработаны для работы с последовательностями данных. В задаче распознавания дифейков стандартные RNN и LSTM анализируют изменения между кадрами, выявляя динамические закономерности, характерные для сгенерированного видео. Часто в работах встречаются гибридные модели CNN (например, ResNet [22] , EfficientNet [23] или MobileNet [24]) + LSTM. CNN извлекает пространственные признаки из каждого отдельного кадра, а затем LSTM

обрабатывает эту последовательность признаков, чтобы принять окончательное решение о том, является ли видео фейком.

Для задачи распознавания фейковых видео часто применяется анализ кадров определенных участков лица или признаки, извлеченные с них. Наиболее интересные участки лица - области щек, с которых обычно извлекается физиологические сигналы (rPPG - remote photoplethysmography)[25], глаза, рот. Модели распознавания фейковых видео также широко используют 3D сетку лица (468 или 478 точек лица) и 68 опорных точек лица, которые называются лендмарками. С rPPG сигналами связано много работ, однако программная реализация и предобученные модели практически во всех отсутствуют.

Сигнал rPPG описывает кровоток или локальные изменения объема крови. Одним из часто используемых методов на основе rPPG модальности является модель DeepFakesOn-Phys [11]. Она использует CAN (convolution attention network), которая извлекает пространственную и временную информацию из видеокадров, анализируя и комбинируя оба источника для лучшего обнаружения поддельных видео. Из более современных работ можно выделить SOTA-метод Sync-rPPG [25], который объединяет в своей архитектуре CNN, LSTM и механизм внимания.

Из моделей, работающих с опорными точками лица, можно выделить методы на основе RNN. LRNet [10] является легковесной моделью, которая анализирует геометрические признаки лица (68 ключевых точек) для выявления несоответсвий между кадрами и неестественных выражений лица. Также хорошие результаты показывает модель на базе RNN в работе [26]. Много внимания уделяется анализу взгляда, глаз и области вокруг них [27].

Однако, ключевой проблемой всех перечисленных методов остается обобщение. Модели, показывающие точность до 99 процентов на данных из

одной выборки (например, FF++ [3], CelebDF [2]), часто резко теряют в эффективности при тестировании на незнакомых манипуляциях. Это указывает на то, что модели могут "запоминать"специфические артефакты конкретного метода генерации.

2 Глава 2. Реализованный подход

2.1 Сбор данных

Данная работа выполнялась в рамках совместного проекта НИУ ВШЭ с компанией "Хуавей". Для обучения моделей распознавания фейковых видео использовался датасет VCDF-X, который был собран участниками группового проекта.

Используемая версия датасета VCDF-X содержит 13 768 клипов, включая 4 151 реальных и 9 713 синтетических видео. В рамках данной работы было сгенерировано 96 видео методом Deep Live Cam, а также собрано 599 реальных клипов.

2.1.1 Сбор реальных видео

Реальные видео были собраны из общедоступного контента YouTube под лицензиями Creative Commons, с фокусом на записи, схожие с форматом видео-конференций, с разнообразным освещением, качеством камеры и поведением людей. Набор реальных данных включает разные разрешения (HD, Full HD и др), частоту кадров и среднюю длину клипа около 24 секунд; более длинные видео были сегментированы для сохранения временной согласованности. Для разделения длинного видео на более короткие клипы (длиной 20-35 секунд) использовалась модель Whisper [28], которая определяла границы предложений, предсказывая временные метки для целых речевых отрезков на уровне фраз или предложений для семантической согласованности внутри каждого клипа.

2.1.2 Сбор синтетических видео

В рамках данной работы тестировались также модели StableAvatar, MoDA, FuseAnyPart [29]. От метода StableAvatar пришлось отказаться из-за высокого потребления графической памяти (GPU), объема которой не хватило для генерации видео данным методом, используя вычислительный кластер НИУ ВШЭ и Yandex Data Sphere. Для генерации 1 секунды видео StableAvatar потребовалось 64 ГБ GPU. Использование метода MoDA, несмотря на хорошее качество генерируемых видео, также оказалось затруднительным в виду нехватки вычислительных ресурсов. Длина сгенерированных видео не смогла превысить 3 секунд. От SOTA-метода FuseAnyPart пришлось отказаться в виду отсутствия предобученных весов в свободном доступе.

Большинство фейковых видео сгенерировано другими участниками проекта такими современными высокопроизводительными моделями, как LiveAvatar (14B) [30] и LTX-2 [31]. Синтетические видео охватывают различные коммуникационные сценарии, включая видеоконференции, видеозвонки один-на-один и записи в стиле "селфи".

Всего для создания VCDF-X использовались 9 методов генерации видео, охватывающие замену лица, воспроизведение лица, и полностью генеративные подходы:

- Замена лица: Deep Live Cam [7], DreamID-V [32], FaceFusion [33], VisoMaster [34].



Рис. 1: Лицо для замены



Рис. 2: Лицо с реального видео



Рис. 3: Пример замены лица с помощью Deep Live Cam

- Воспроизведение лица: SadTalker [35], LiveAvatar [30]
- Контент, сгенерированный ИИ: Ovi (11B) [36], LTX-2 (19B) [31]

Также для генерации видео использовались искусственные лица, сгенерированные с помощью Z-Image-Turbo [37] и StyleGAN2 [38].



Рис. 4: Пример сгенерированного лица Z-image-Turbo



Рис. 5: Пример сгенерированного лица StyleGAN2

2.1.3 Мультимодальная аннотация и аугментации

- В дополнение к RGB-данным в данной работе извлекается набор вспомогательных модальностей для каждого видео в датасете. Извлечена

геометрия лица, включая лицевую сетку из 468 точек, посредством MediaPipe, а также 68 ключевых точек с помощью dlib. Сигналы дистанционной фотоплетизмографии (rPPG) оценивались с помощью dlib, OpenCV, numpy и scipy в рамках теста модели DeepFakesOn-Phys [11].



Рис. 6: Кадр из фейкового видео датасета VCDF-X

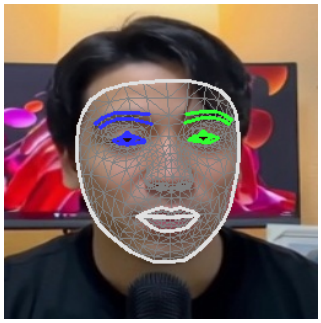


Рис. 7: Face mesh (сетка лица) из 468 точек

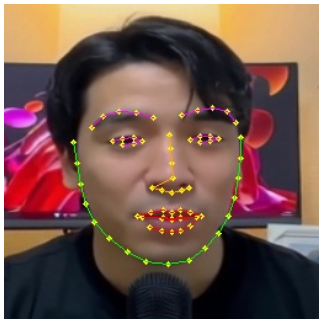


Рис. 8: Face mesh (сетка лица) из 68 точек

- Для анализа датасета из каждого видео также извлекались следующие метаданные: гендер, национальность, возраст, эмоции. Демографические и эмоциональные данные получены с помощью EmotieffLib [40]. В рамках данной работы метаданные были извлечены для 4 513 видео, для остальных - силами других участников проекта.

- Для повышения устойчивости будущей модели к условиям реальных онлайн-конференций к части реальных видео (10 процентов) применены реалистичные аугментации: имитация ручной съёмки (тряска камеры), помехи (гауссовский шум), перемена освещения и задержки видео-потока, а также эффекты засвета. Данные преобразования позволяют моделировать типичные артефакты видеосвязи и обучать детектор отличать их от признаков генерации. Данные аугментации сде-

ланы при помощи инструментов библиотек OpenCV, SciPy и NumPy.



Рис. 9: Кадр изначального видео

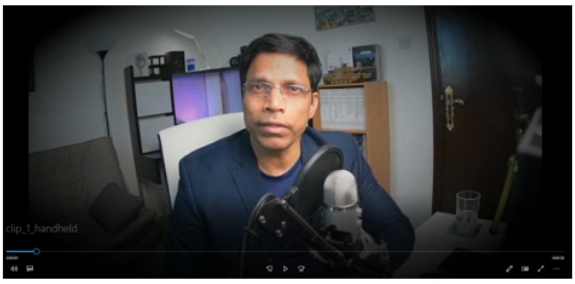


Рис. 10: Кадр видео с применением шума и дерганием камеры



Рис. 11: Кадр видео с задержкой видео-потока



Рис. 12: Кадр видео с засветом

Ниже приведены графики метаданных, показывающие состав датасета по типу видео (реальное, синтетическое), гендеру, возрасту, этнической принадлежности и эмоциям.

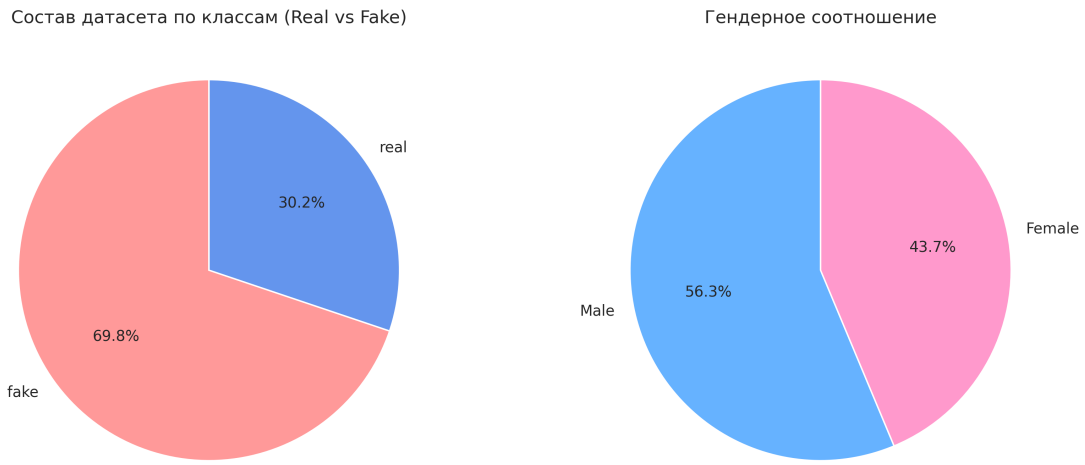


Рис. 13: Состав датасета по реальным и синтетическим видео (слева) и гендерное распределение датасета (справа)

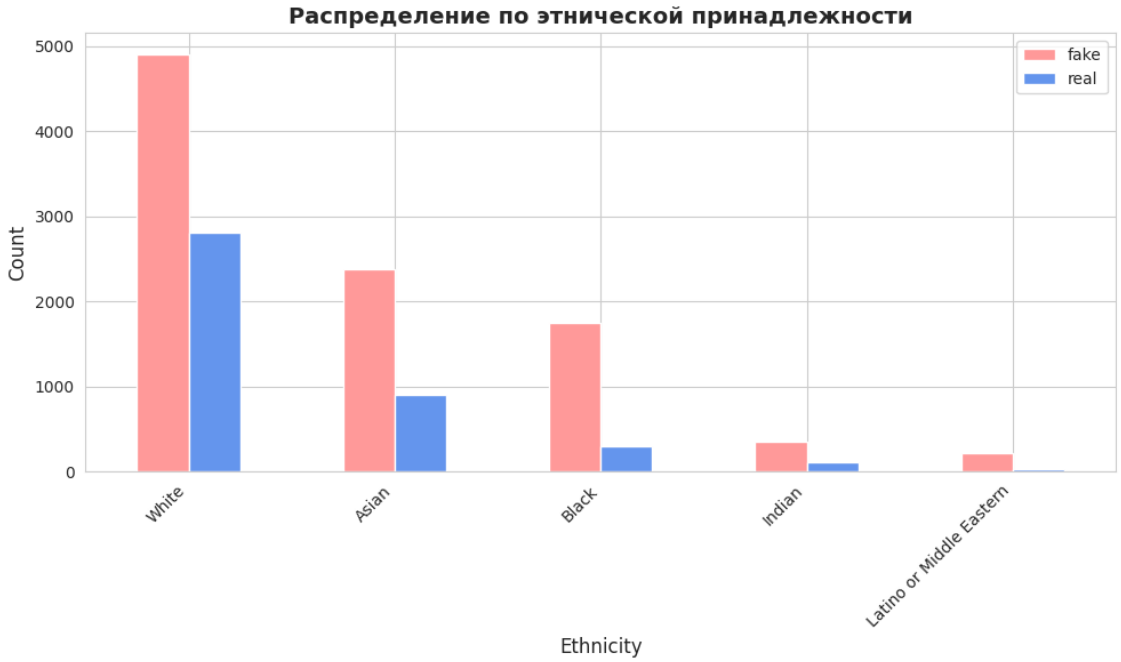


Рис. 14: Распределение этнической принадлежности в датасете

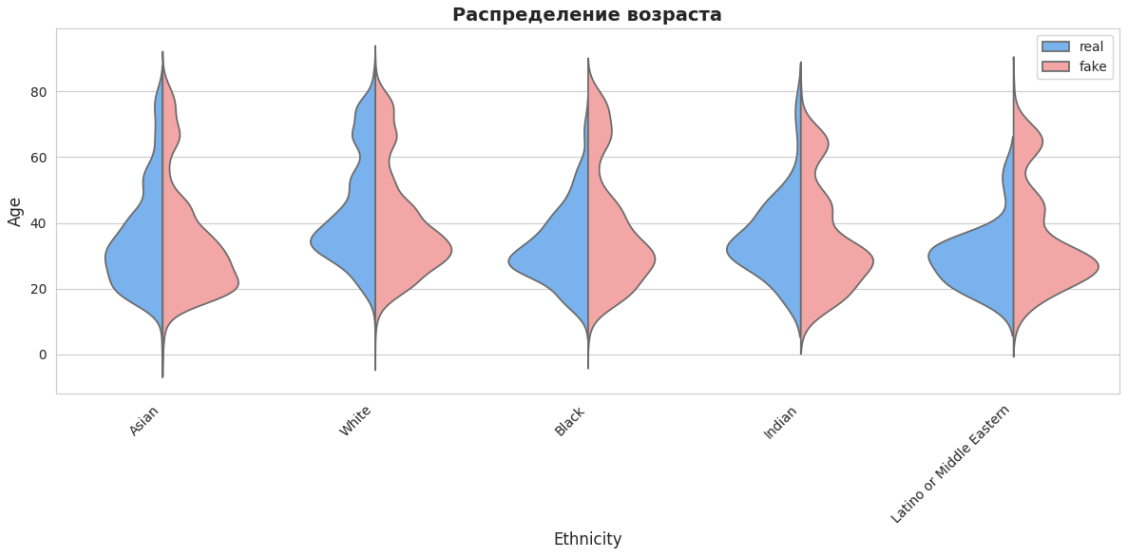


Рис. 15: Распределение этнической принадлежности и возрасту в датасете

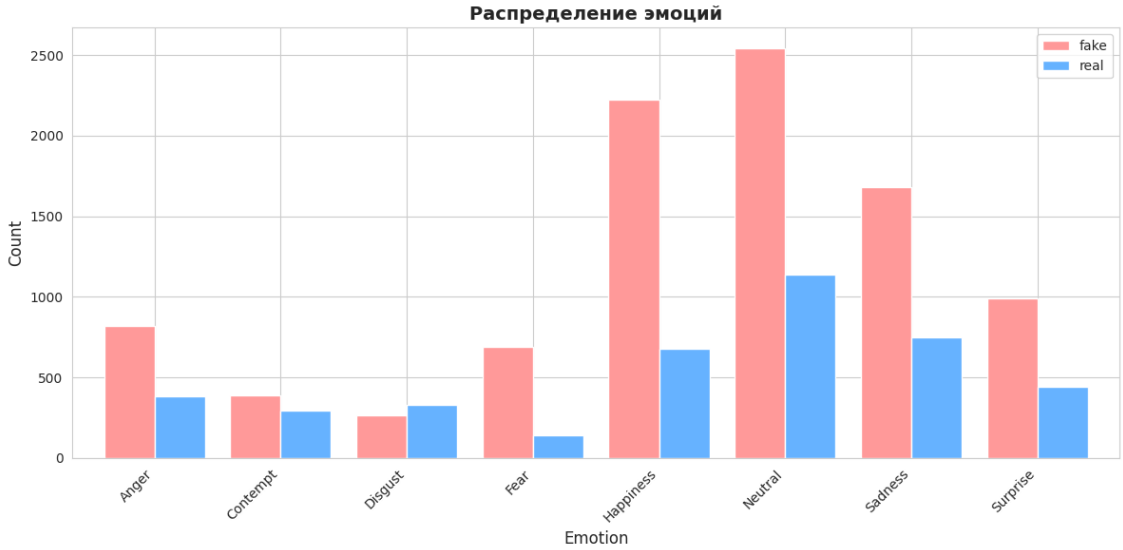


Рис. 16: Распределение эмоций в датасете

2.1.4 Предобработка данных

Перед обучением моделей была выполнена следующая обработка данных:

- Из каждого видео случайным образом выбирался фрагмент длиной 1-2 секунды (64 последовательных кадра), и этот фрагмент разбивался

на кадры. Фрагменты выбраны таким образом, что на всех кадрах определено лицо.

- Затем для каждого кадра выполнялась детекция лица с последующим ресайзом полученной области до размера 256×256.

Таким образом, для обучения моделей классификации были подготовлены последовательности из 64 кадров с лицами для каждого видео.

2.2 Алгоритм распознавания синтетических видео

Итоговое решение содержит в себе 3 обученные модели:

- ResNet50+LSTM, обученная на кадрах с полными лицами;
- ResNet50+LSTM, обученная на кадрах только с глазами;
- LRNet, изначально обученная на FF++ [3], CelebDF [2] и UADFV и дообученная на собранном датасете VCDF-X.

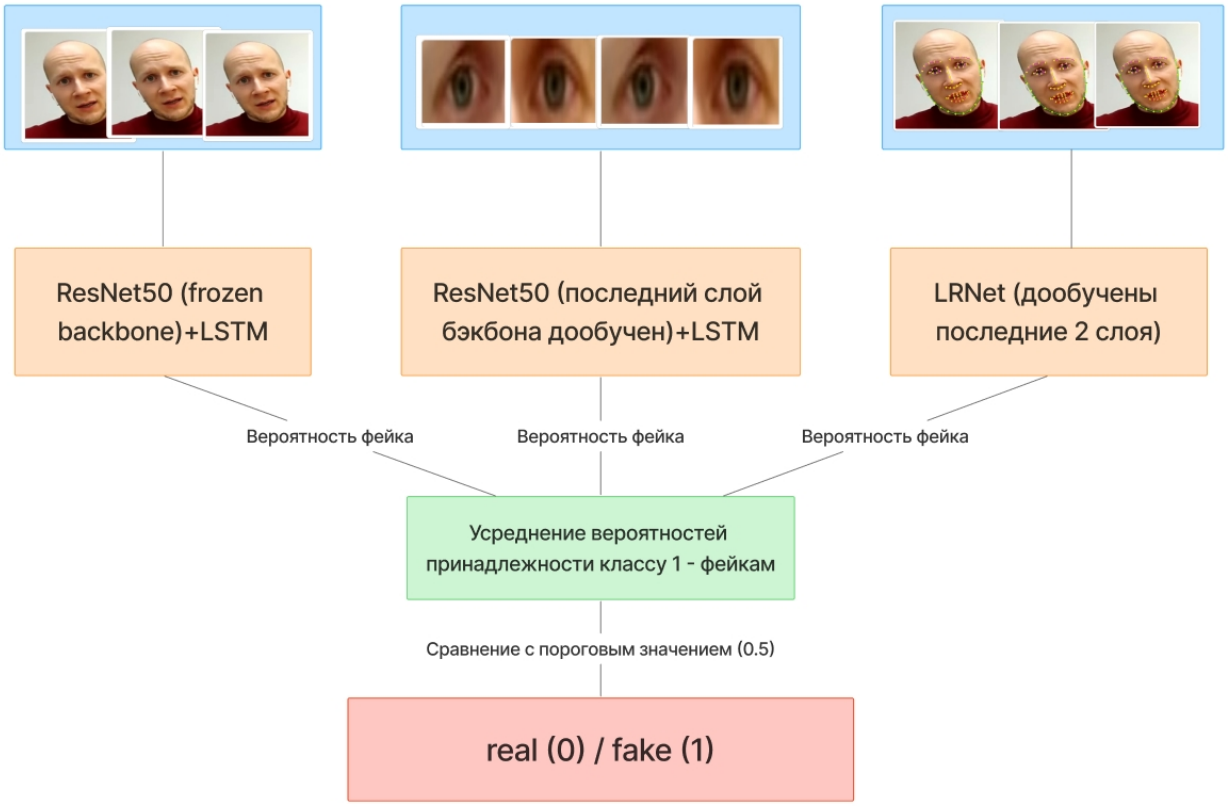


Рис. 17: Схема итоговой модели

Алгоритм работы детектора: на вход подается видео, из него извлекаются 64 последовательных кадра, на которых определяется лицо и применяется ресайз до размера 256x256. Далее 16 кадров отдаются на вход в ResNet50 и LSTM, на них же извлекаются глаза и передаются в другую гибридную модель ResNet50+LSTM. 60 кадров проходят обработку для модели LRNet (извлекаются 68 точек лица, происходит уточнение их координат). На выходе все 3 модели выдают вероятность принадлежности данной последовательности кадров к классу синтетических видео. Эти вероятности усредняются, видео определяется как фейк, если результат не менее 0.5.

В качестве моделей для работы непосредственно с кадрами были взяты стандартная сверточная нейронная сеть ResNet50 и реккурентная сеть LSTM, которые показали хорошие результаты в экспериментах, описанных

далее в работе.

В качестве модели для обучения на лендмарках лица была выбрана LRNet (Landmark recurrent network) [10]. Она фокусируется на 68 ключевых точках лица, отслеживая геометрические особенности, неестественные микродвижения лицевых мышц и временные разрывы в последовательности кадров.

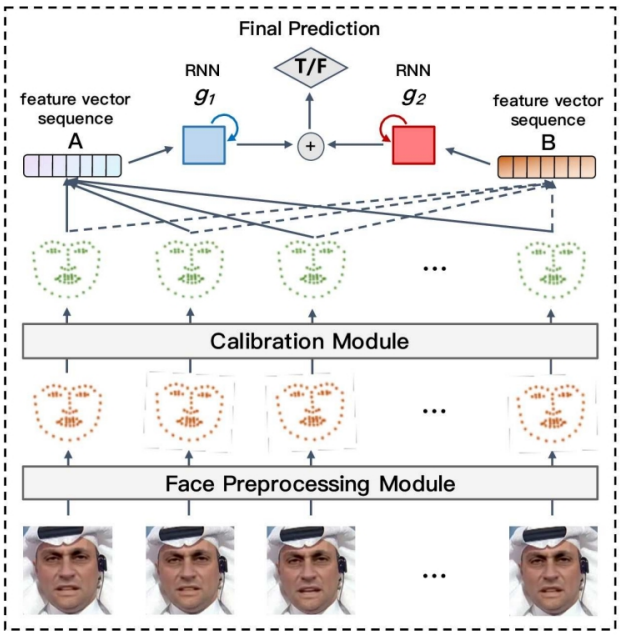


Рис. 18: Архитектура LRNet

1. На вход подается 68 2D опорных точек лица, описывающих контуры глаз, бровей, носа, губ. Затем точки выравниваются относительно эталонного положения с помощью аффинного преобразования. Далее с помощью алгоритма Лукаса-Канаде предсказывается положение точек в следующем кадре. Следом происходит предсказание прошлого положения и ошибочные предсказания отбрасываются. Далее результаты детекции и предсказания объединяются и вычисляется оптимальное сглаженное положение каждой точки с помощью фильтра Калмана.

2. Для каждого кадра формируется два типа векторов: α - конкатенация координат 68 точек: $[x_1, y_1, x_2, y_2, \ldots, x_{68}, y_{68}]$, β - разности координат между кадрами (скорость движения): $\beta = \alpha_{t+1} - \alpha_t$

3. Классификация (двухпоточная RNN)

   - Поток g_1: Bidirectional GRU (Gated Recurrent Unit) (64 units) обрабатывает последовательность α — моделирует паттерны формы лица;
   - Поток g_2: Bidirectional GRU (64 units) обрабатывает последовательность β — выявляет временные несоответствия;
   - Выходы обоих потоков проходят через полносвязные слои, результаты усредняются для финального предсказания.

3 Глава 3. Результаты экспериментов

Задача распознавания синтетических видео является задачей бинарной классификации. В работе используются следующие метки: 1 - fake, 0 - real. Для определения качества работы моделей были использованы следующие метрики:

$$\text{Precision} = \frac{TP}{TP + FP} \tag{1}$$

$$\text{Recall} = \frac{TP}{TP + FN} \tag{2}$$

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2 \cdot TP}{2 \cdot TP + FP + FN} \tag{3}$$

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \tag{4}$$

Для оценки качества бинарного классификатора также использовалась метрика *Area Under the ROC Curve* (AUC-ROC). ROC-кривая отражает зависимость доли верно предсказанных положительных примеров (TPR - true positive rate) от доли ложных срабатываний (FPR - false positive rate) при варьировании порога классификации.

Датасет VCDF-X был разбит на обучающую, валидационную и тестовую выборки следующим образом:

- обучающая: 4128 фейковых и 3199 реальных видео
- валидационная: 339 фейковых и 168 реальных видео
- тестовая: 1162 фейковых видео и 467 реальных видео

При обучении моделей состав данных выборок был дополнительно сбалансирован по классам. Также для тестирования моделей был предоставлен набор данных от компании “Хуавей”, обозначаемый в дальнейшем в скобках (hw).

3.1 Итоговая модель

В итоговом решении используются веса трех моделей, описанных в экспериментах ниже. Для задачи объединения результатов работы этих моделей было рассмотрено несколько вариантов:

1. Обучение логистической регрессии на вероятностях принадлежности видео к классу 1 (fake) от трех моделей, тем самым придавая определенный вес выходу каждой модели.

   Данный подход показал слабые результаты на тестовых данных (hw). Получившиеся метрики: Accuracy = 0.6, F1 = 0.64, AUC = 0.71, precision = 0.88, recall = 0.5.

2. Голосование моделей. Если хотя бы 2 модели выдают вероятность не менее 0.5, видео определяется как фейк.

   Данный подход оказался более успешным, показав следующие метрики на тестовых данных (hw): Accuracy = 0.75, F1 = 0.81, AUC = 0.88, precision = 0.88, recall = 0.75.

3. Усреднение вероятностей. Каждая из 3 моделей вносит одинаковый вклад. Такой подход показал наилучшие результаты на тестовых данных (hw): Accuracy = 0.78, F1 = 0.83, AUC = 0.88, precision = 0.88, recall = 0.79

3.2 Другие подходы и эксперименты

3.2.1 RGB-модальность

RGB-каналы являются стандартными признаками, с которыми работают модели на базе CNN, в частности, для классификации изображений. Так как видео является последовательностью кадров, то и работа модели осуществлялась с последовательными кадрами.

В рамках данной работы для rgb-модальности были дообучены несколько стандартных моделей классификации изображений с ипользованием подхода transfer learning.

ResNet50 + LSTM

1. **CNN**

   В качестве основы используется ResNet50, предобученная на ImageNet. Из ResNet50 удаляется последний полносвязный классификационный слой. Вместо этого сеть используется для извлечения признаков из каждого отдельного кадра видео.

   Входной тензор имеет форму (batch_size, frames, C, H, W), где batch_size — размер батча, frames — количество кадров в последовательности, C, H, W — каналы, высота, ширина кадра.

   Каждый кадр последовательно подаётся в CNN. Получается вектор признаков размером 2048. Векторы всех кадров склеиваются в тензор формы (batch_size, frames, 2048).

2. **LSTM**

   Принимает на вход последовательность векторов признаков, полученных CNN для всех обработанных кадров видео. LSTM анализирует,

как меняются признаки от кадра к кадру, и учится выявлять временные зависимости.

3. **Классификатор**

   Из выходной последовательности LSTM берется состояние последнего временного шага, которое содержит информацию обо всей последовательности. Это состояние передается в классификатор из двух полносвязных слоев с функцией активации ReLU и dropout, который выдает логиты для двух классов: fake (1) и real (0).

Обучение модели на 16 кадрах и на 32 кадрах дало схожие результаты, поэтому было принято решение использовать в данном случае 16 последовательных кадров для меньших временных затрат на обучение.

Эксперимент 1: у ResNet50 берется замороженный бэкбон, поэтому веса CNN не обновляются во время обратного распространения ошибки. Модель обучает только слой LSTM и классификатор. Лучшие метрики получились после 4 эпохи. Функция потерь - кросс-энтропия, оптимайзер - AdamW, шаг обучения (learning rate) равен 0.00001, dropout 0.5.

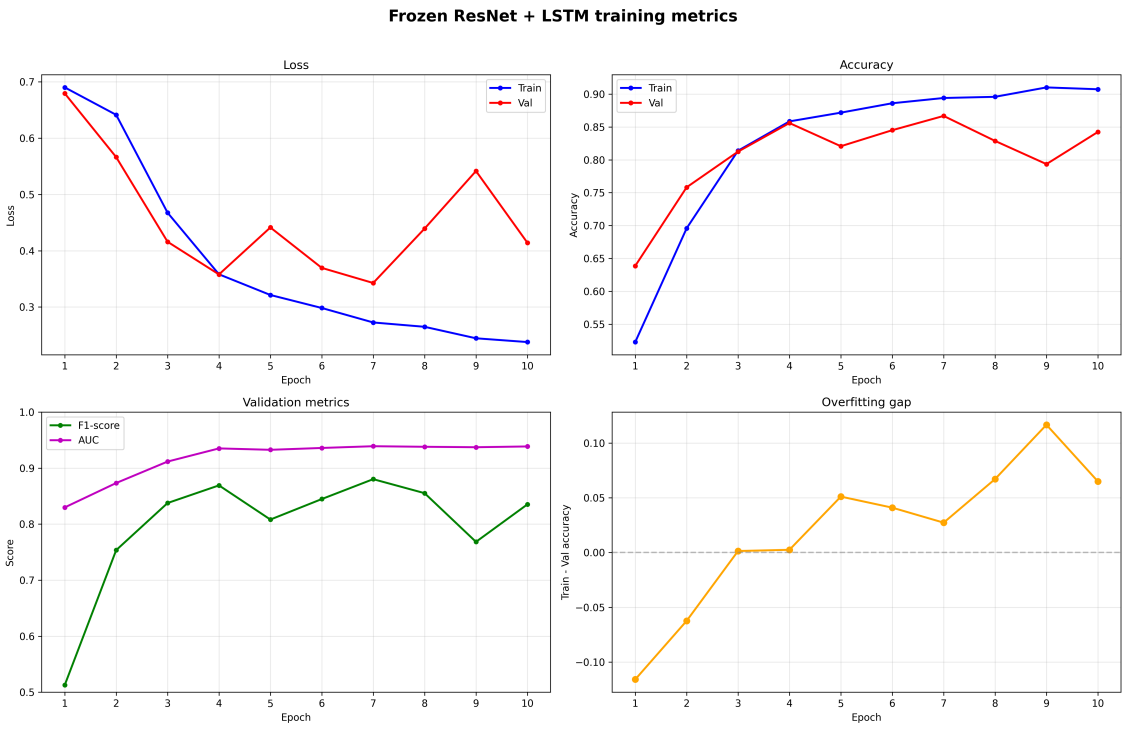


Рис. 19: Графики обучения (замороженная ResNet + LSTM)

На графиках наблюдается нестабильное поведение модели после четвертой эпохи: лосс на валидации начинает расти, а метрики идут на снижение. Это свидетельствует о переобучении модели после 4 эпох.

Полученные метрики на тестовой части VCDFX:

- AUC = 0.94
- F1 = 0.88
- Accuracy = 0.85

Полученные метрики на тестовом датасете (hw):

- AUC = 0.71
- F1 = 0.75
- Accuracy = 0.69

Модель показала неплохие результаты как на датасете VCDF-X, так и на абсолютно новых данных. Веса данной модели взяты для использования в итоговом решении задачи распознавания фейковых видео. Время классификации (fake/real) для одного видео: 74 мс на T4 GPU в фреймворке Kaggle.

Эксперимент 2: Последний слой бэкбона ResNet50 размораживается и вместе с LSTM и классификатором обучается на новых данных в течение 10 эпох, шаг обучения равен 0.000001 (оптимайзер AdamW).

Результаты работы на тестовой части VCDF-X:

- Accuracy=0.93
- F1=0.94
- AUC=0.99

Результаты работы на тестовом датасете (hw):

- AUC = 0.51
- F1 = 0.42
- Accuracy = 0.68

Несмотря на хорошие метрики на тестовой части датасета VCDF-X, модель неспособна корректно отрабатывать на новых данных. Это может быть из-за того, что модель, обученная таким образом, слишком сильно подстраивается к артефактам и особенностям именно тех методов генерации, что использовались в данном датасете.

Модель ResNet50 была выбрана для задачи распознавания фейковых видео, так как она обучена на датасете ImageNet-1K, который содержит бо-

лее миллиона изображений и 1000 классов. Также она показывала отличные результаты с transfer learning подходом для других задач классификации.

RexNet150

Используется модель RexNet (Rank Expansion Network), веса предобученной модели взяты из репозитория HSEMotion [40]. Данная модель была выбрана для обучения, так как она достаточно легковесная, а также была предобучена на датасете VGGFace2. При замороженном бэкбоне обучались слои классификатора в течение 8 эпох.

Входной тензор также имеет форму (batch_size, frames, C, H, W). Каждый кадр последовательно подаётся в CNN. Получается вектор признаков размером 180 (размерность признаков для RexNet150). Векторы всех кадров склеиваются в тензор формы (batch_size, frames, 180). Для анализа последовательности кадров применяется temporal mean pooling — усреднение признаков по всем кадрам видео. Далее усреднённый вектор признаков подаётся в полносвязный слой (классификатор), состоящий из 2 линейных слоев с функцией активации ReLU, батч-нормализацией и регуляризацией (dropout). Параметры обучения: learning rate равен 0.0003 (оптимайзер AdamW), размер батча 16, количество кадров также 16.

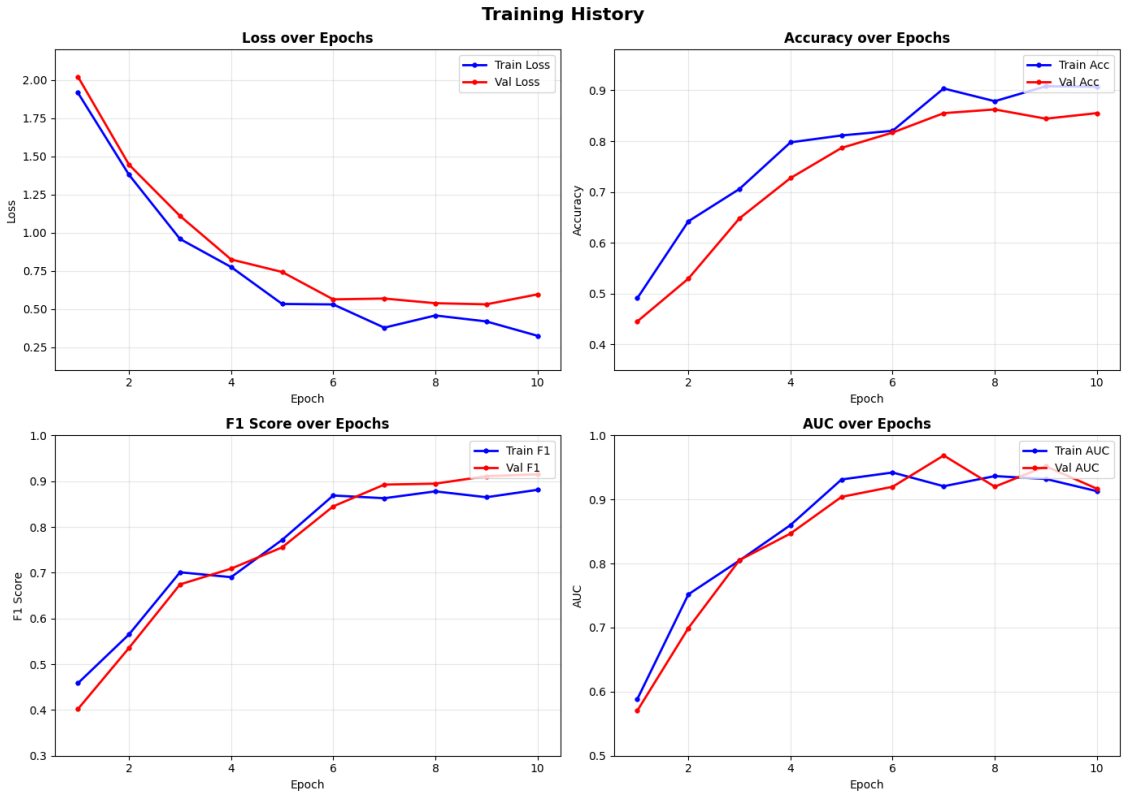


Рис. 20: Графики обучения RexNet150

Результаты на тестовой части VCDF-X:

- Accuracy = 0.87
- AUC = 0.95
- F1 = 0.9

Результаты на тестовом датасете (hw):

- Accuracy = 0.4
- AUC = 0.55
- F1 = 0.37

Несмотря на хорошие метрики на тестовой выборке, модель показала себя плохо на новых данных. Ее обобщающие способности недостаточны, чтобы определить фейковые видео в новом наборе данных.

Для обучения ResNet50 и RexNet150 к датасету применены трансформации, стандартные для ImageNet.

3.2.2 Признаки, извлеченные с глаз

К данным признакам была применена модель ResNet50 с LSTM, описанная выше в работе. С каждого кадра делались кропы обоих глаз, модель обучалась только на них (16 кадров для каждого видео). Все слои бэкбона модели ResNet50, кроме последнего, замораживались. Параметры обучения: 15 эпох, шаг обучения 0.000001, регуляризация weight decay равна 0.001, dropout равен 0.2, функция потерь – кросс-энтропия.

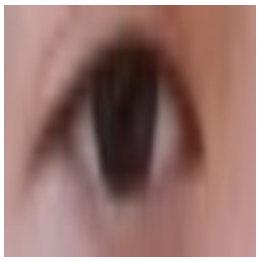


Рис. 21: Левый глаз

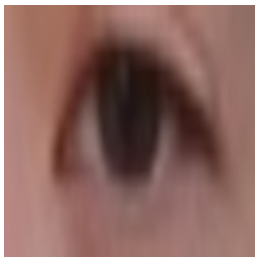


Рис. 22: Правый глаз

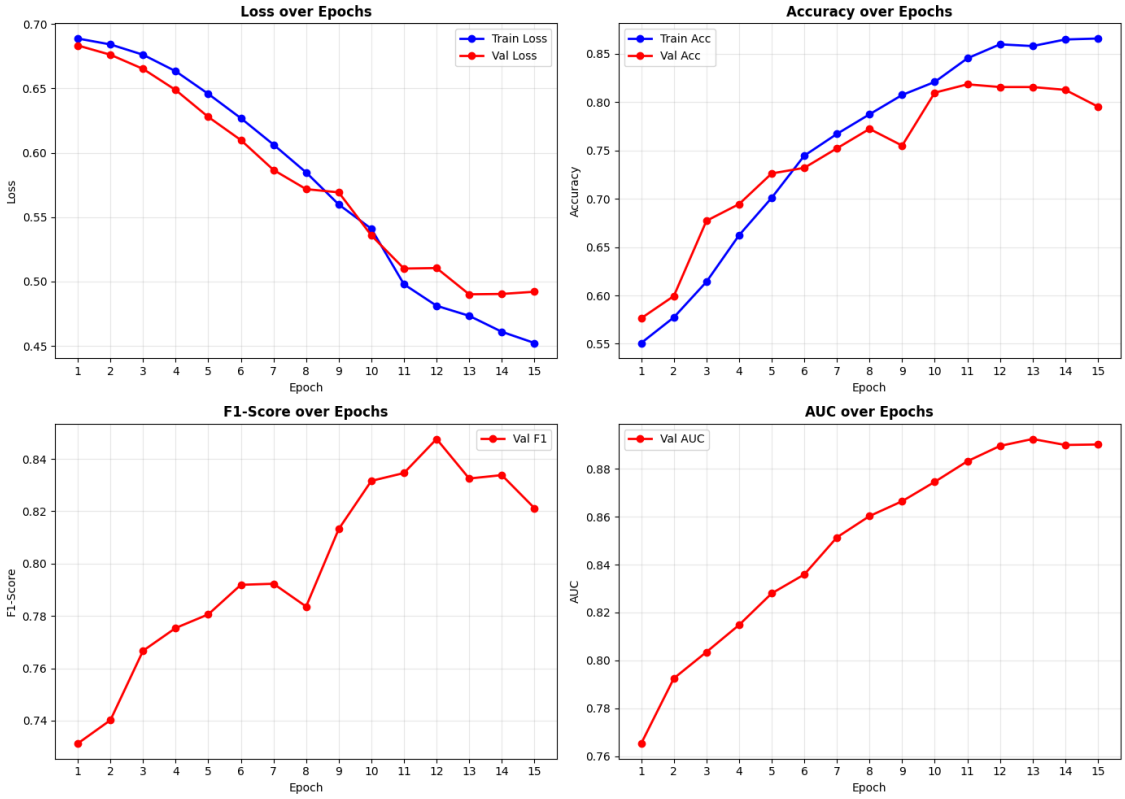


Рис. 23: Графики обучения ResNet50+LSTM на кадрах с глазами

Лучшие метрики на тестовых данных получились по результатам 12 эпохи.

Результаты на тестовой части VCDF-X:

- Accuracy = 0.86
- AUC = 0.87
- F1 = 0.93

Результаты на тестовом датасете (hw):

- Accuracy = 0.73
- AUC = 0.78
- F1 = 0.82

Данная модель оказалась одной из лучших по результатам на новых данных. Обучение на кропах с глазами показало лучшие метрики, чем обучение на полных кадрах. Это можно объяснить тем, что глаза являются наиболее уязвимым местом фейковых лиц, таким образом отражая неестественные движения от кадра к кадру. Однако использование только такого подхода может быть не очень эффективно, так как против моделей, хорошо генерирующих глаза, а остальные части лица хуже, данный подход не будет работать.

Веса этой обученной модели взяты для использования в итоговом решении.

3.2.3 Facial landmarks

LRNet

Для данной модальности дообучалась модель LRNet [10]. Эта модель показала хорошие метрики на датасетах FF++ (AUC 0.99) и UADFV (AUC 0.98).

Принцип работы: последовательность опорных точек, извлеченная с кадров (68 точек с каждого), после дополнительных преобразований встраивается в последовательность векторов признаков двух типов, а затем подается на вход двухпоточной (g1, g2) рекуррентной нейронной сети для классификации видео.

Параметры обучения: learning rate (шаг обучения) для g1 и g2 равен 0.00002, количество эпох для g1 и g2 равно 25.

Результаты на тестовом датасете (hw):

- до дообучения на датасете VCDF-X: Accuracy = 0.53, F1 = 0.58, AUC = 0.51

- после дообучения на датасете VCDF-X: Accuracy = 0.74, F1 = 0.84, AUC = 0.79

Обучение модели LRNet на датасете VCDF-X, содержащем качественные синтетические видео и реальные видео в разном разрешении, улучшило способности модели к распознаванию современных видов подделывания человеческого лица в условиях конференцсвязи.

BiLSTM

Данная модель была выбрана для обучения на лендмарках, так как она позволяет учитывать информацию как из прошлых кадров, так и из будущих, что критически важно для отслеживания движения мышц на лице человека. На вход подается последовательность из 32 кадров, каждый кадр содержит 478 ключевых точек лица с 3 координатами (x,y,z). Это сетка лица и контур.

Модель принимает на вход тензор формы `(batch_size, seq_len, lm, coords)`, где seq_len — количество кадров в последовательности, lm — количество лендмарков, coords — координаты на точку (x, y, z). Признаки всех лендмарков объединяются в один вектор размером 1434 на каждый кадр. Применяется BatchNorm1d для стабилизации обучения и ускорения сходимости, нормализация выполняется по временной оси. LSTM обрабатывает последовательность в прямом и обратном направлениях, учитывая контекст из прошлых и будущих кадров одновременно. Далее применяется механизм внимания, где вычисляется важность каждого кадра. Выходы LSTM умножаются на соответствующие веса внимания и суммируются по временной оси в контекстный вектор. Классификационный слой состоит из 3 линейных слоев, батч-нормализации и функции активации ReLU, также применяется регуляризация (dropout).

Параметры обучения: 30 эпох, шаг обучения равен 0.0001 (оптимайзер AdamW), dropout равен 0.4, функция потерь – кросс-энтропия.

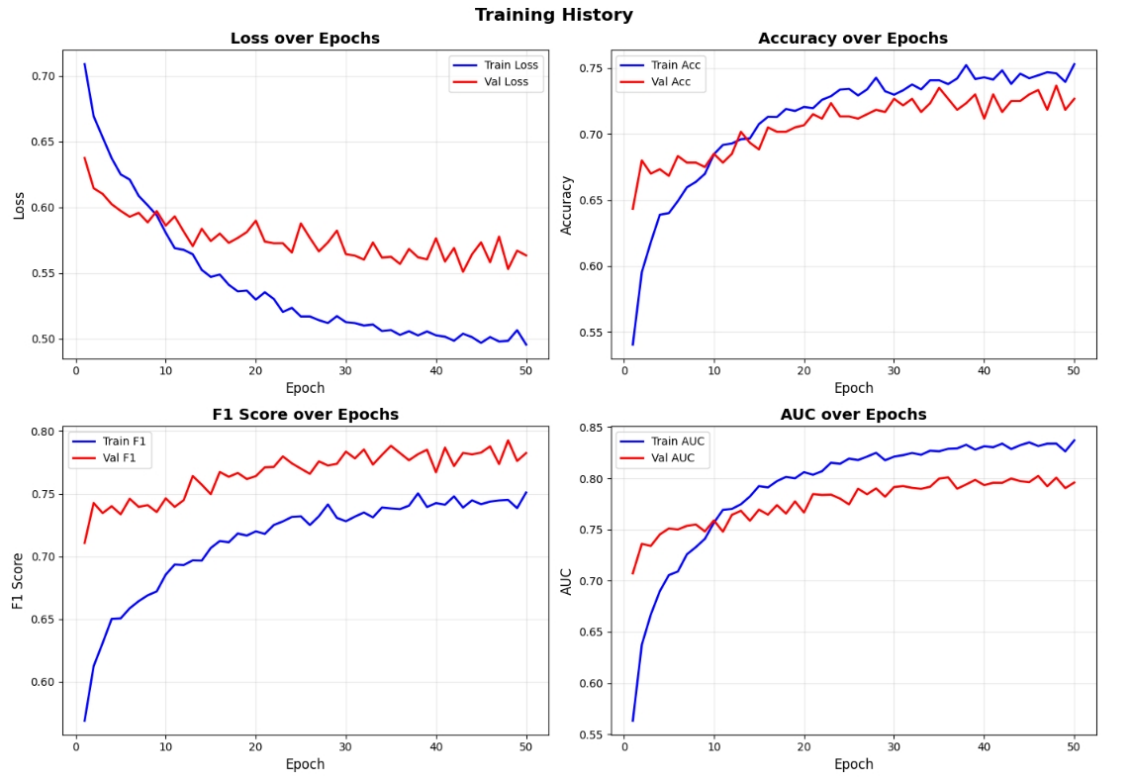


Рис. 24: Графики обучения модели BiLSTM

Результаты на тестовой части VCDF-X:

- Accuracy: 0.69
- F1: 0.74
- AUC: 0.79

Результаты на тестовом датасете (hw):

- Accuracy: 0.60
- F1: 0.62
- AUC: 0.58

Данная модель обучается нестабильно, на новых данных показывает невысокие результаты. Изменение параметров обучения не привело к более хорошим результатам.

3.2.4 rPPG

DeepFakesON-Phys

Модель DeepFakesOn-Phys [11] показала хорошие результаты на датасетах CelebDF(v2) (AUC 0.999) и DFDC preview (AUC 0.982), поэтому была выбрана для дообучения на датасете VCDF-X.

Модель была взята с предобученными весами, дообучались последние 2 слоя бэкбона и классификатор. В результате экспериментов с различными параметрами обучения (learning rate, количество эпох) не удалось корректно дообучить модель на новых данных. Метрики (auc, accuracy, f1) не поднимались выше 0.6.

Такой результат может быть обусловлен тем, что современные модели генерации видео, использованные при сборе датасета VCDF-X, научились имитировать физиологические сигналы на уровне, неразличимом для существующих детекторов.

Таблица 1: Результаты экспериментов с различными моделями

Модель	**Обучение**	**Тестирование**	**Accuracy**	**AUC**	**F1**
ResNet50+LSTM (замороженный бэкбон)	VCDF-X	VCDF-X	0.85	0.94	0.88
		Тестовый датасет (hw)	0.69	0.71	0.75
ResNet50+LSTM (обучался последний слой бэкбона)	VCDF-X	VCDF-X	0.93	0.99	0.94
		Тестовый датасет (hw)	0.68	0.51	0.42
RexNet150	VCDF-X	VCDF-X	0.87	0.95	0.90
		Тестовый датасет (hw)	0.40	0.55	0.37
ResNet50+LSTM на кадрах с глазами (обучался последний слой бэкбона)	VCDF-X	VCDF-X	0.86	0.87	0.93
		Тестовый датасет (hw)	0.73	0.78	0.82
LRNet (дообучение)	VCDF-X	Тестовый датасет (hw)	0.74	0.79	0.84
LRNet (исходные веса)	–	Тестовый датасет (hw)	0.53	0.51	0.58
BiLSTM	VCDF-X	VCDF-X	0.69	0.79	0.74
		Тестовый датасет (hw)	0.60	0.58	0.62
Итоговая модель (логистическая регрессия, обученная на выходных вероятностях)	VCDF-X	Тестовый датасет (hw)	0.60	0.71	0.64
Итоговая модель (голосование 3 моделей)	–	Тестовый датасет (hw)	0.75	0.88	0.81
Итоговая модель (усреднение вероятностей)	–	Тестовый датасет (hw)	0.78	0.88	0.83

3.3 Использованные вычислительные ресурсы

Для генерации видео использовался вычислительный кластер Харизма, выделенный НИУ ВШЭ, а также кластер университета ИТМО.

Для вспомогательных задач (сбор ральных видео, разбиение на короткие клипы, аугментации, выделение метаданных, анализ состава датасета и разбиение видео на кадры с выделением лица) и для обучения моделей были использованы бесплатные ресурсы из Google Colab и Kaggle, а именно GPU T4.

Заключение

В ходе выполнения данной работы было проведено исследование проблемы распознавания синтетических видео, созданных с использованием современных методов генерации на основе искусственного интеллекта. Актуальность данного исследования обусловлена стремительным развитием технологий создания дипфейков и участившимися случаями их применения в мошеннических схемах. В рамках данной работы исследованы современные методы генерации видео. Проведен анализ SOTA-методов создания синтетических видео, включая подходы на основе замены лица и воспроизведения лица на базе GAN и диффузионных трансформеров, что в свою очередь внесло вклад в создание репрезентативного датасета, содержащего видео в формате онлайн конференций. В результате изучения методов генерации видео можно сделать вывод о высоком качестве генерируемых результатов современными моделями, некоторые из которых требуют значительных вычислительных мощностей. Также исследованы различные архитектуры и модальности, проведены эксперименты с гибридными моделями на основе CNN и RNN. В результате проведенных экспериментов можно отметить неспособность некоторых моделей, обученных на датасетах FF++ [3], CelebDF [2], UADFV, определять фейковые видео, сгенерированные SOTA-методами, даже при дообучении на более качественных данных, а также слабую обобщающую способность моделей, показывающих высокие метрики на тестовом наборе датасета VCDF-X, так как на новых данных они часто демонстрируют существенное снижение качества. Это говорит о проблеме переобучения на специфических артефактах конкретных методов генерации. Несмотря на значительное количество неудачных экспериментов, удалось добиться значений AUC и F1 выше 0.8, что свидетельствует

о пригодности применения некоторых протестированных алгоритмов для задачи распознавания фейковых видео на текущий момент. Реализованный в работе ансамблевый подход, состоящий из трех моделей, каждая из которых отвечает за определенные признаки, показывает более высокие результаты, чем использование отдельных архитектур. Это объясняется наличием артефактов и неестественных движений на разных участках лица. Использование моделей, предобученных на крупных датасетах как для задачи распознавания фейков (LRNet), так и для других задач компьютерного зрения (ResNet50), демонстрирует лучшее качество обучения на собранном датасете, в то время как обучение ранних слоев предобученных моделей зачастую приводит к запоминанию обучающей выборки и низким метрикам на новых данных. Протестированные подходы показали перспективы использования сетки лица и области вокруг глаз для задачи распознавания сгенерированного контента, так как ключевые точки лица связаны с движениями мышц, а неестественные движения глаз, форма радужки и блики часто становятся проблемой при создании синтетических видео, особенно продолжительных. В отличие от данных модальностей, использование физиологических признаков (rPPG) и дообучение предобученной модели на новом датасете не привело к хорошему результату. В последних исследованиях отмечается, что современные методы создания фейков генерируют реалистичные признаки живого человека [42]. Результаты данной работы демонстрируют перспективность мультимодального подхода с анализом микровыражений лиц в задаче распознавания фейковых видео, а также достаточно хорошие результаты работы ансамблевой модели на данных, сгенерированых современными методами. Однако, применение реализованного в работе подхода в режиме реального времени может быть затруднительно в виду долгой предобработки данных для модели, обученной на лендмарках лица.

Список литературы

[1] Редакция Tochka. Сотрудник перевёл 25 миллионов долларов со счёта компании после разговора с дипфейком начальника. *Tochka*, 8 февраля 2024. `https://allo.tochka.com/news/deepfake-fraud`

[2] Li, Y., Yang, X., Sun, P., Qi, H., & Lyu, S. Celeb-DF: A large-scale challenging dataset for deepfake forensics. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 3207-3216, 2020.

[3] Rossler, A., Cozzolino, D., Verdoliva, L., Riess, C., Thies, J., & Nießner, M. FaceForensics++: Learning to detect manipulated facial images. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp. 1-11, 2019.

[4] Dolhansky, B., Bitton, J., Pflaum, B., Lu, J., Howes, R., Wang, M., & Ferrer, C. C. The deepfake detection challenge (dfdc) dataset. *arXiv preprint arXiv:2006.07397*, 2020.

[5] Thies, J., Zollhofer, M., Stamminger, M., Theobalt, C., & Nießner, M. Face2Face: Real-time face capture and reenactment of RGB videos. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 2387–2395, 2016.

[6] Deepfakes. FaceSwap. *GitHub repository*, 2018. `https://github.com/deepfakes/faceswap`

[7] Hacksider. Deep Live Cam. *GitHub*, 2024. `https://github.com/hacksider/deep-live-cam`

[8] Li, X., Li, G., Lin, Z., Qian, Y., Yao, G., Jia, W., ... & Wang, F. MoDA: Multi-modal Diffusion Architecture for Talking Head Generation. *arXiv preprint arXiv:2507.03256*, 2025.

[9] Tu, S., Pan, Y., Huang, Y., Han, X., Xing, Z., Dai, Q., ... & Jiang, Y. G. Stableavatar: Infinite-length audio-driven avatar video generation. *arXiv preprint arXiv:2508.08248*, 2025.

[10] Sun, Z., Han, Y., Hua, Z., Ruan, N., & Jia, W. Improving the efficiency and robustness of deepfakes detection through precise geometric features. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 3609–3618, 2021.

[11] Hernandez-Ortega, J., Tolosana, R., Fierrez, J., & Morales, A. Deepfakes detection based on heart rate estimation: Single- and multi-frame. In *Handbook of Digital Face Manipulation and Detection: From DeepFakes to Morphing Attacks*, pp. 255–273. Cham: Springer International Publishing, 2022.

[12] MarekKowalski. FaceSwap. *GitHub repository.* `https://github.com/MarekKowalski/FaceSwap/`

[13] Thies, J., Zollhofer, M., & Nießner, M. Deferred neural rendering: Image synthesis using neural textures. *ACM Transactions on Graphics (TOG)*, 2019.

[14] Goodfellow, I. J., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., ... & Bengio, Y. Generative adversarial nets. In *Advances in Neural Information Processing Systems*, vol. 27, 2014.

[15] Prajwal, K. R., Mukhopadhyay, R., Namboodiri, V. P., & Jawahar, C. V. A lip sync expert is all you need for speech to lip generation in the wild. In *Proceedings of the 28th ACM International Conference on Multimedia*, pp. 484–492, 2020. doi: 10.1145/3394171.3413694. `https://github.com/Rudrabha/Wav2Lip`

[16] Cui, J., Li, H., Yao, Y., Zhu, H., Shang, H., Cheng, K., ... & Wang, J. Hallo2: Long-duration and high-resolution audio-driven portrait image animation. In *International Conference on Learning Representations*, vol. 2025, pp. 91659–91671, 2025.

[17] Gan, Q., Yang, R., Zhu, J., Xue, S., & Hoi, S. OmniAvatar: Efficient audio-driven avatar video generation with adaptive body animation. *arXiv preprint arXiv:2506.18866*, 2025. `https://arxiv.org/abs/2506.18866`

[18] Chen, Y., Liang, S., Zhou, Z., Huang, Z., Ma, Y., Tang, J., ... & Lu, Q. HunyuanVideo-Avatar: High-fidelity audio-driven human animation for multiple characters. *arXiv preprint arXiv:2505.20156*, 2025. `https://arxiv.org/abs/2505.20156`

[19] pfrankov. Video Face Swap. *GitHub repository*. `https://github.com/pfrankov/video-face-swap`

[20] Acharya, A. S., Shisal, A. A., Butale, S. K., Latpate, O. B., Deore, S. P., & Latpate, O. A Comprehensive Survey on Detection of Fake Multimedia Content. *Cureus Journals*, 2(1), 2025.

[21] Ahmad Sharawardi, N. S., Liew, S.-H., Turumugon, P., & Subramaniam, A. Review of Deepfake Detection Techniques and Challenges. In *Proceedings of the 2025 IEEE International Conference on Computation,*

Big-Data and Engineering (ICCBE), pp. 867–872, 2025. doi: 10.1109/ICCBE65177.2025.11255645.

[22] Bhandarkawthekar, V., Navamani, T. M., Sharma, R., & Shyamala, K. Design and development of an efficient RLNet prediction model for deepfake video detection. *Frontiers in big Data*, 8, 1569147, 2025.

[23] Pawar, S. B., & Nalavade, K. C. Comparative Analysis of Hybrid Deep Learning Models for Deepfake Detection. In *2025 International Conference on Transformative Computing Technologies (ICTCT)*, pp. 110–116, 2025.

[24] Subhasri, N., Gangadhar, M., Divakar, M., Goud, N. E. B. C., Ramaraju, M., & Sreenivasulu, K. A Hybrid MobileNet-LSTM Model for Enhanced Detection of Deepfake Media in Real-Time Image and Video Analysis. In *2025 5th International Conference on Expert Clouds and Applications (ICOECA)*, pp. 1099–1106, 2025.

[25] Susi, A., Akila, V., & Govindasamy, V. Utilizing rPPG Signal Synchronization and Deep Learning Techniques for Deepfake Video Detection. *IEEE Access*, 2025.

[26] Carter, B., Dilla, N., Callahan, M., & Ambala, A. Deepfake Detection Via Facial Feature Extraction and Modeling. *arXiv preprint arXiv:2507.18815*, 2025. `https://arxiv.org/abs/2507.18815`

[27] He, Q., Peng, C., Liu, D., Wang, N., & Gao, X. GazeForensics: DeepFake Detection via Gaze-guided Spatial Inconsistency Learning. *arXiv preprint arXiv:2311.07075*, 2023. `https://arxiv.org/abs/2311.07075`

[28] Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C., & Sutskever, I. Robust speech recognition via large-scale weak supervision. In

Proceedings of the International Conference on Machine Learning (ICML), pp. 28492–28518, 2023.

[29] Yu, Z., Wang, Y., Cui, S., Zhang, A., Zheng, W. L., & Wang, S. FuseAnyPart: Diffusion-driven facial parts swapping via multiple reference images. In *Advances in Neural Information Processing Systems*, vol. 37, pp. 80864–80884, 2024.

[30] Huang, Y., Guo, H., Wu, F., Wang, W., Zhang, S., Huang, S., ... & Hoi, S. Live avatar: Streaming real-time audio-driven avatar generation with infinite length. *arXiv preprint arXiv:2512.04677*, 2025.

[31] HaCohen, Y., Brazowski, B., Chiprut, N., Bitterman, Y., Kvochko, A., Berkowitz, A., ... & Farbman, Z. LTX-2: Efficient Joint Audio-Visual Foundation Model. *arXiv preprint arXiv:2601.03233*, 2026.

[32] Guo, X., Ye, F., Li, X., Tu, P., Zhang, P., Sun, Q., ... & He, Q. DreamID-V: Bridging the Image-to-Video Gap for High-Fidelity Face Swapping via Diffusion Transformer. *arXiv preprint arXiv:2601.01425*, 2026.

[33] FaceFusion. *Website*. `https://facefusion.io`

[34] VisoMaster. *Website*. `https://visomaster.com`

[35] Zhang, W., Cun, X., Wang, X., Zhang, Y., Shen, X., Guo, Y., ... & Wang, F. SadTalker: Learning realistic 3d motion coefficients for stylized audio-driven single image talking face animation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 8652-8661, 2023.

[36] Low, C., Wang, W., & Katyal, C. Ovi: Twin backbone cross-modal fusion for audio-video generation. *arXiv preprint arXiv:2510.01284*, 2025.

[37] Cai, H., Cao, S., Du, R., Gao, P., Hoi, S., Hou, Z., . . . & Zhou, S. Z-image: An efficient image generation foundation model with single-stream diffusion transformer. *arXiv preprint arXiv:2511.22699*, 2025.

[38] Karras, T., Laine, S., & Aila, T. A style-based generator architecture for generative adversarial networks. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 4401–4410, 2019.

[39] Lugaresi, C., Tang, J., Nash, H., McClanahan, C., Uboweja, E., Hays, M., Zhang, F., Chang, C.-L., Yong, M. G., Lee, J., *et al.* Mediapipe: A framework for building perception pipelines. *arXiv preprint arXiv:1906.08172*, 2019.

[40] Savchenko, A. V. Hsemotion: High-speed emotion recognition library. *Software Impacts*, page 100433, Dec 2022.

[41] Yadav, S., & Mangalampalli, S. S. Deepfake defense: Combining spatial and temporal cues with CNN–BiLSTM–transformer architecture. *PLoS One*, 20(11), e0334980, 2025.

[42] Seibold, C., Wisotzky, E. L., Beckmann, A., Kossack, B., Hilsmann, A., & Eisert, P. High-quality deepfakes have a heart! *Frontiers in Imaging*, vol. 4, p. 1504551, 2025.

Приложение

Код для предобработки данных и обучения моделей можно найти в репозитории на github: https://github.com/mispasyuk/Diploma